

דוח מטלה 1 – איסוף נתוני סרטים


קורס כריה וניתוח נתונים מתקדם | חלק 1 מתוך 3

מקורות: IMDb Non-Commercial Datasets & Wikipedia scraping

סקירה כללית

מטלה זו בונה סט נתונים מקיף ואיכותי של סרטי קולנוע (ללא סדרות טלוויזיה), אשר ישמש בסיס לבניית מודלי חיזוי ואפליקציית Flask בחלקים הבאים של הפרויקט. הנתונים נאספו מהטבלאות הציבוריות של **IMDb** ומ-**Wikipedia** (באמצעות web scraping בלבד — ללא API).

טווח כיסוי: סרטים שכותרתם מתחילה באותיות **Bm עד Bz** (חלוקת עומס בין קבוצות הקורס).



צינור עיבוד הנתונים (Pipeline)

הנתונים עוברים את השלבים הבאים בסדר:



החלטות שנלקחו בבניית סט הנתונים

סינון לסוג "movie" בלבד

הוצאו סדרות טלוויזיה, מיני-סדרות, פרקים וכו' – רק `titleType == 'movie'` נכלל. הדבר מבטיח שהמודל מתאמן על ז'אנר אחד.

הגבלת טווח שנים עד 2024

סרטים משנת 2025 ואילך אינם כלולים. הגבלה זו מבטיחה שנתוני הדירוג מ-IMDb מספיק מבוססים (מספיק ימי הצגה לאיסוף דירוגים).

סינון משך סרט 300–60 דקות

סרטים קצרים מ-60 דקות הם לרוב סרטים קצרים (short films) שאינם מייצגים קולנוע מסחרי. סרטים ארוכים מ-300 דקות הם אירועים חריגים שעלולים לעוות את המודל.

LEFT JOIN (לא INNER JOIN) עם דירוגים

שימוש ב-LEFT JOIN שומר על כל הסרטים גם ללא דירוג. סרטים ישנים רבים אינם מדורגים ב-IMDb אך עדיין בעלי ערך לניתוח.

לקיחת עד 5 שחקנים מובילים

מטבלת `title.principals`, סינון ל- `category == 'actor'` ומיון לפי `ordering`. נבחרו עד 5 שחקנים ראשונים (קרדיט) לכל סרט. בחירה זו מאזנת בין כיסוי לפשטות.

cache לבקשות Wikipedia

כל תוצאת Wikipedia נשמרת בקובץ `wiki_cache.json`. בהרצה חוזרת הנתונים נטענים מה-cache ואין בקשות כפולות לשרת.

ממוצע עבור טווחי תקציב/הכנסות

כאשר Wikipedia מציגה טווח (לדוגמה "20–25 מיליון דולר"), מחושב הממוצע ומוחזר ערך יחיד כמספר עשרוני.

פילטרים מיושמים

עמודה	תנאי הסינון	ערך	סיבה
<code>titleType</code>	שווה ל	<code>'movie'</code>	הוצאת סדרות, מיני-סדרות, פרקים וכל מה שאינו סרט קולנוע
<code>startYear</code>	קטן-שווה	<code>2024</code>	הגבלת טווח שנים לפי דרישת המטלה; סרטי 2025+ אינם כלולים
<code>runtimeMinutes</code>	בין (כולל)	<code>60 - 300</code>	הסרת סרטים קצרים מדי (short films) וסרטים ארוכים חריגים
<code>primaryTitle</code> 2)	בין (lowercase)	<code>'bm' - 'bz'</code>	חלוקת עומס בין קבוצות הקורס לפי אותיות ראשונות

קוד הסינון (לוגיקה)

לאחר טעינת `title.basics.tsv.gz`, הפילטרים מיושמים בסדר הבא:

- 1. שמירת שורות שבהן `titleType == 'movie'`
- 2. המרת `startYear` לנומרי וסינון `startYear ≤ 2024`
- 3. המרת `runtimeMinutes` לנומרי וסינון לטווח 300–60
- 4. חישוב 2 האותיות הראשונות (lowercase) של `primaryTitle` וסינון לטווח `bm-bz`

לוגיקת ה-Joins

JOIN 1 – דירוגי IMDb (title.ratings)

פרמטר	ערך
סוג	LEFT JOIN
מפתח חיבור	tconst
טבלה שמאלית	טבלת הסרטים המסוננת (title.basics)
טבלה ימנית	title.ratings.tsv.gz
עמודות שנוספו	numVotes , averageRating
סרטים ללא דירוג	נשמרים עם NaN בעמודות הדירוג (1,726 סרטים, 25.9%)

JOIN 2 – שחקנים מובילים (title.principals + name.basics)

פרמטר	ערך
סינון מוקדם	category == 'actor' בלבד
מיון	לפי tconst ואחר-כך ordering (סדר קרדיט)
צבירה (GroupBy)	groupby('tconst').head(5) → עד 5 שחקנים ראשונים
צבירת מזהים	groupby('tconst')['nconst'].apply(list)
סוג JOIN	LEFT JOIN על tconst
עמודה שנוספה	lead_actors_ids (רשימת מחרוזות nconst)
סרטים ללא שחקנים	נשמרים עם רשימה ריקה []

JOIN 3 – נתוני Wikipedia (web scraping עם threading)

לכל סרט מנסים עד 3 כתובות URL ב-Wikipedia (לפי שנה → (film) → שם גולמי). הכל מבוצע באמצעות **scraping בלבד (BeautifulSoup)** — ללא שום API. ה-scraping רץ עם `ThreadPoolExecutor(max_workers=5)` המאפשר 5 סרטים במקביל. מה-infobox נחלצות:

העלילה (`plot`) נחלצת מקטע Plot/Synopsis , או `BoxOffice` , `budget` , `Country` , `Language` .
מפסקת הפתיחה כ-`fallback` . התוצאות מאוחדות עם הטבלה הראשית באמצעות `pd.concat` לפי אינדקס.

תיאור שדות סט הנתונים

שם עמודה	סוג	מקור	תיאור
tconst	String	IMDb	מזהה ייחודי של הסרט ב-IMDb (לדוגמה: tt0000502)
primaryTitle	String	IMDb	שם הסרט הראשי (כפי שמופיע ב-IMDb)
startYear	Integer	IMDb	שנת יציאה לאקרנים (1905–2024)
genres	List[String]	IMDb	רשימת ז'אנרים כפי שמופיעה ב-IMDb (לדוגמה: ['Drama', 'Comedy'])
lead_actors_ids	List[String]	IMDb	עד 5 מזהי nconst של שחקנים מובילים לפי סדר קרדיט ('category='actor')
runtimeMinutes	Integer	IMDb	משך הסרט בדקות (60–300)
averageRating	Float	IMDb	ממוצע דירוג IMDb בסקלה 1.0–10.0
Language	String	Wikipedia	השפה הראשית של הסרט (חולץ מ-infobox של Wikipedia)
Country	String	Wikipedia	מדינת ההפקה הראשית (חולץ מ-infobox של Wikipedia)
numVotes	Integer	IMDb	מספר המשתמשים שדירגו את הסרט ב-IMDb
budget	Float	Wikipedia	תקציב הפקה במיליוני USD; אם מוצג טווח – מחושב ממוצע
BoxOffice	Float	Wikipedia	הכנסות גלובליות במיליוני USD; אם מוצג טווח – מחושב ממוצע

שם עמודה	סוג	מקור	תיאור
plot	String	Wikipedia	תקציר העלילה (הפסקה הראשונה מדף Wikipedia)

ערכים חסרים לפי עמודה

סה"כ 6,668 סרטים. הטבלה מציגה את מספר הערכים החסרים ואחוזם לכל עמודה.

עמודה	מקור	ערכים חסרים	אחוז חסר	ויזואליזציה
tconst	IMDb	0	0.0%	שלם
primaryTitle	IMDb	0	0.0%	שלם
startYear	IMDb	0	0.0%	שלם
genres	IMDb	0	0.0%	שלם
lead_actors_ids	IMDb	0	0.0%	שלם
runtimeMinutes	IMDb	0	0.0%	שלם
averageRating	IMDb	1,726	25.9%	סרטים ישנים רבים אינם מדורגים ב-IMDb
numVotes	IMDb	1,726	25.9%	זהה ל-averageRating (אותן שורות)
Language	Wikipedia	4,801	72.0%	רוב הסרטים ישנים/עצמאיים ואין להם דף Wikipedia
Country	Wikipedia	4,794	71.9%	זהה ל-Language
budget	Wikipedia	6,335	95.0%	תקציב מוצג רק בסרטים מסחריים בולטים

עמודה	מקור	ערכים חסרים	אחוז חסר	ויזואליזציה
BoxOffice	Wikipedia	6,268	94.0%	הכנסות מוצגות רק בסרטים מסחריים בולטים
plot	Wikipedia	4,761	71.4%	נחלץ מקטע Plot/Synopsis או פסקת פתיחה בדף Wikipedia

הערה על ערכים חסרים מ-Wikipedia

שיעור הערכים החסרים בעמודות Wikipedia (~88–97%) נובע בעיקר מכך שרוב הסרטים בקורפוס (בעיקר ישנים, עצמאיים, או זרים) פשוט אינם מופיעים ב-Wikipedia בכלל. הסרטים שכן נמצאו הם לרוב הפקות מסחריות ידועות.

- שדות `budget` ו- `BoxOffice` חסרים גם בדפים שנמצאו — לא כל סרט תועד פיננסית
- שדה `plot` מחולץ גם מפסקת הפתיחה כ-`fallback`, מה שמגדיל משמעותית את הכיסוי

הערכים החסרים **אינם מוסרים** מסט הנתונים — נשמרים כ-`NaN` כדי לאפשר למודל בחלק השני להחליט כיצד להתמודד עמם.

שיפורי מנגנון ה-Scraping

בעקבות ניתוח מעמיק של מבנה דפי Wikipedia ובעיות הכיסוי, בוצעו השיפורים הבאים:

השפעה	תיקון שבוצע	בעיה שאובחנה
Language: 6% → 28.0%	מחיקת רשומות all-None בטעינה + אי-שמירת כישלונות חדשים	Cache שמר כישלונות לצמיתות — 93% מהרשומות היו קפואות כ- None מריצה גרועה
ממוצע טווחים מחושב נכון	Normalize - → - לפני הפרסור	<code>parse_money</code> לא טיפל ב-en-dash (U+2013) — <code>\$5.7–6.5M</code> החזיר ערך שגוי
כיסוי נוסף לסרטים עם שמות כפולים	זיהוי <code>div#disambigbox</code> ← מעקב לקישור הסרט לפי שנה	דפי Disambiguation לא זוהו — <code>Boys Don't Cry</code> הכניס דף שגוי
חיפוש מוצלח יותר	מעבר ל-href slug להתאמה — אמין יותר	Search fallback השתמש בטקסט הקישור (מגיע <code>:squished</code> (<code>BruceAlmighty</code>)
plot: 1.2% → 28.6%	בדיקה ראשית של fallback , <code>div.mw-heading</code> לסגנון ישן	קטע HTML: Plot חדש של Wikipedia משתמש ב- <code>div.mw-heading</code> ולא ב- <code></code>
fallback לפסקת פתיחה עובד	ירידה לרמה הנכונה לפני איטרציה	Lead section: פסקאות נמצאות ב- <code>div.mw-parser-output</code> ולא ישירות ב- <code>div#mw-content-text</code>
ריצה מהירה יותר	Sleep רק כשנמצאה דף בפועל (<code>did_fetch</code>)	Sleep על 404 — בזבוז זמן על סרטים שאינם ב-Wikipedia

מקורות הנתונים

שדות שנאספו	קובץ / כתובת	מקור
tconst, titleType, primaryTitle, startYear, runtimeMinutes, genres	title.basics.tsv.gz	IMDb title.basics
averageRating, numVotes	title.ratings.tsv.gz	IMDb title.ratings
lead_actors_ids של nconst) (שחקנים)	title.principals.tsv.gz	IMDb title.principals
Language, Country, budget, BoxOffice, plot	en.wikipedia.org	Wikipedia scrapping בלבד